Visão Computacional - Lista 6

Aqui serão resolvidas as atividades da terceira lista de Visão Computacional pelo aluno Sillas Rocha da Costa, começaremos realizando alguns imports:

In [1]:
```
import cv2 as cv2
import numpy as np
from matplotlib import pyplot as plt
```

Exercício 1 - SIFT (Scale Invariant Feature Transform)

In [2]:
```
imagem1 = cv2.imread('./keble_a.jpg')
imagem2 = cv2.imread('./keble_b.jpg')
imagem3 = cv2.imread('./keble_c.jpg')

cinza1 = cv2.cvtColor(imagem1, cv2.COLOR_BGR2GRAY)
cinza2 = cv2.cvtColor(imagem2, cv2.COLOR_BGR2GRAY)
cinza3 = cv2.cvtColor(imagem3, cv2.COLOR_BGR2GRAY)
```

In [3]:
```
plt.imshow(cinza2, cmap='gray')
```

Out[3]:
```
<matplotlib.image.AxesImage at 0x12eda64edb0>
```

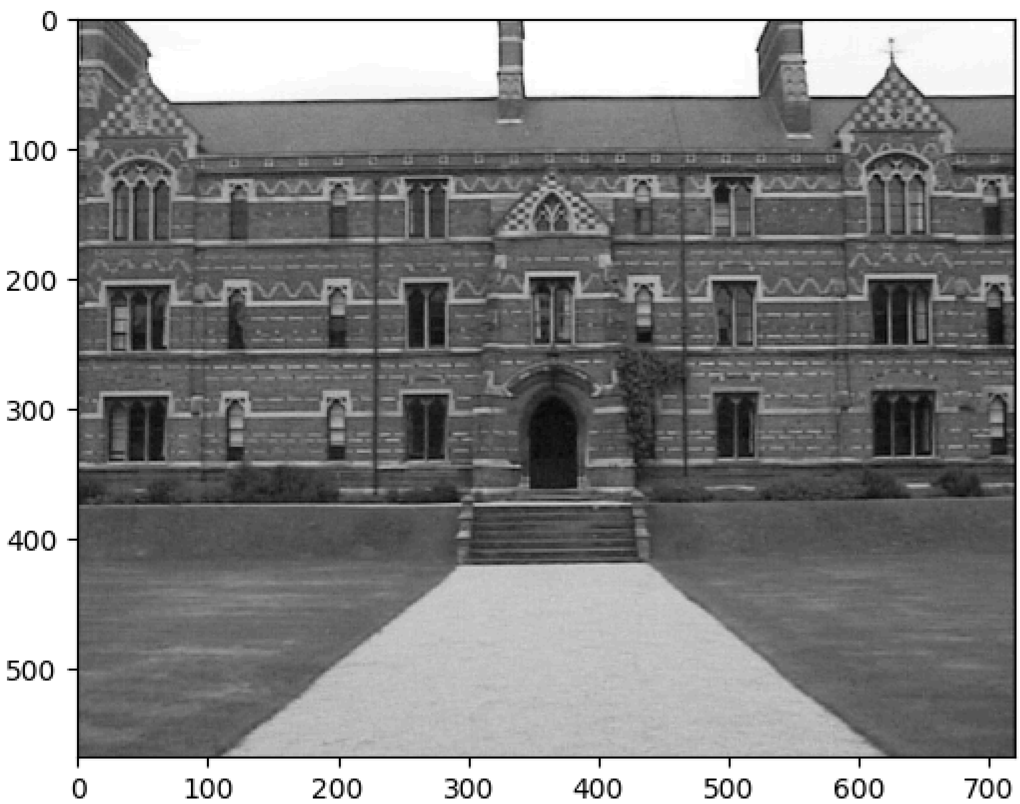

In [4]:
```
sift = cv2.SIFT_create()
pontos1, descritores1 = sift.detectAndCompute(cinza1, None)
pontos2, descritores2 = sift.detectAndCompute(cinza2, None)
pontos3, descritores3 = sift.detectAndCompute(cinza3, None)
```

In [5]:
```
imagem_com_circulos = cv2.drawKeypoints(imagem1, pontos1, None, flags=cv2.DRAW_MATCHES_FLAGS_DRAW

# cv2.imshow('SIFT Features', imagem_com_circulos)
# cv2.waitKey(0)
# cv2.destroyAllWindows()
```

In [6]:
```
index_params = dict(algorithm=0, trees=5)
search_params = dict()

matcher = cv2.FlannBasedMatcher(index_params, search_params)
matches = matcher.knnMatch(descritores1, descritores2, k=2)

good_matches = []
for m, n in matches:
    if m.distance < 0.75 * n.distance:
        good_matches.append(m)
```

```
pontos1 = np.float32([pontos1[m.queryIdx].pt for m in good_matches]).reshape(-1, 1, 2)
pontos2 = np.float32([pontos2[m.trainIdx].pt for m in good_matches]).reshape(-1, 1, 2)

matriz_homografia, _ = cv2.findHomography(pontos2, pontos1, cv2.RANSAC, 5.0)
```

In [7]:
```
imagem_unida = cv2.warpPerspective(imagem2, matriz_homografia, (imagem1.shape[1] + imagem2.shape
imagem_unida[0:imagem1.shape[0], 0:imagem1.shape[1]] = imagem1

plt.imshow(imagem_unida[:,:,::-1])
```

Out[7]: `<matplotlib.image.AxesImage at 0x12eda7b4f80>`

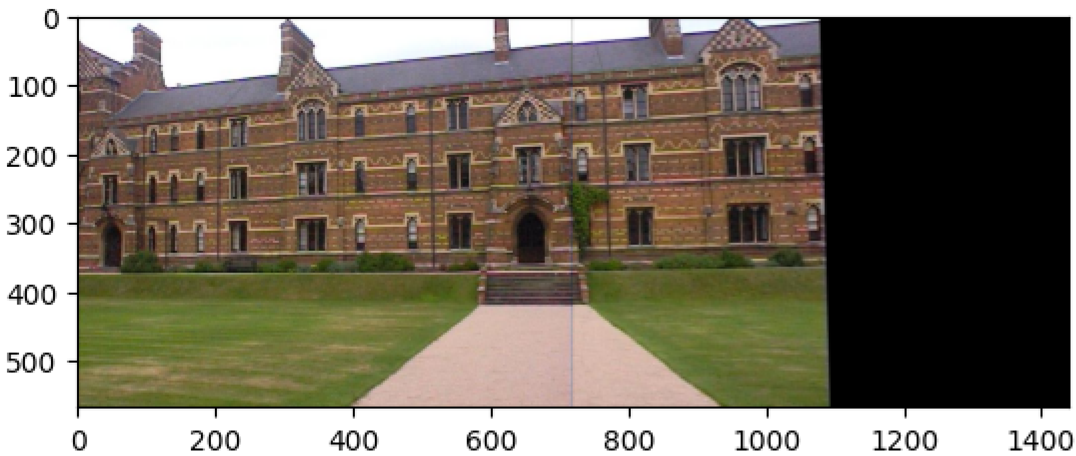

2 - Exercício Teórico

1. Linearidade:

Temos que $L(I,t) = g(t) \circledast I$, assim:

$$L(aI_1 + bI_2, t) = g(t) \circledast (aI_1 + bI_2)$$

mas como a convolução é linear, então:

$$g(t) \circledast (aI_1 + bI_2) = a(g(t) \circledast I_1) + b(g(t) \circledast I_2)$$

Entretanto, sabemos que:

$$a(g(t) \circledast I_1) + b(g(t) \circledast I_2) = aL(I_1, t) + bL(I_2, t)$$

Portanto ela é linear.

2. Invariância por translação:

Como $L(I,t) = \hat{I}(x,y,t) = g(t) \circledast I$, onde tal convolução é dado por:

$$\hat{I}(x,y,t) = (g(t) \circledast I)(x,y) = \iint_{\R^2} g(x-s, y-r, t) I(s,r) ds dr$$

Então, se I for transladado, resultará em $\hat{I}(x-\Delta x, y-\Delta y, t)$, de modo que:

$$(g(t) \circledast I)(x-\Delta x, y-\Delta y) = \iint_{\R^2} g((x-\Delta x)-s, (y-\Delta y)-r, t) I(s,r) ds dr$$

Onde, ao realizar uma mudança de coordenada de modo que $u = s + \Delta x$ e $v = r + \Delta y$, teremos:

$$\hat{I}(x-\Delta x, y-\Delta y, t) = \iint_{\R^2} g(x-u, y-v, t) I(u-\Delta x, v-\Delta y) du dv$$

3. Propriedade do semigrupo:

Temos que:

$$L(I,t) = g(t) \circledast I$$

$$L(L(I,t), s) = g(s) \circledast (g(t) \circledast I)$$

Usando a propriedade que a convolução de duas gaussianas é a gaussiana com a soma dos parâmetros, $g(s) \circledast g(t) = g(s+t)$, então:

$$g(s) \circledast (g(t) \circledast I) = g(t+s) \circledast I = L(I, t+s)$$

Provando a propriedade do semigrupo

4. Não ampliação de máximos (e minimos) espaciais:

Como sabemos que o efeito da gaussiana é calcular o valor do novo pixel como a soma ponderada dos pixels na vizinhança, assim, essa soma aplicada a um ponto de máximo, resultará no mesmo valor de máximo ou um valor menor, já que, caso toda a região seja composta de valores de máximo, sua soma ponderada será ele este máximo, caso contrário, se houverem outros valores além do máximo, estes valores serão obviamente menores que o valor de máximo, já que eles não são o valor de máximo, assim, o resultado final será um valor menor que o máximo já que a soma ponderará valores menores diminuindo o resultado final, de maneira análoga aos valores de mínimos, já que, é possível obter ou o valor de mínimo, caso a região seja composta apenas de mínimos, ou um valor maior que o de mínimo, caso a região tenha valores diferentes do de mínimo, que, deverão ser maiores que ele. Deste modo, é exemplificado como não há ampliação de máximos e mínimos.

5. Invariância por Rotação

Queremos achar $L(R_\theta I, t) = R_\theta L(I, t)$, entretanto:

$$L(R_\theta I, t) = g(t) \circledast (R_\theta I)$$

Mas como a concolução com a gaussiana é invariante por rotação, obtemos:

$$g(t) \circledast (R_\theta I) = R_\theta (g(t) \circledast I) = R_\theta L(I, t)$$

Ou seja, invariante por rotação

3 - Extra

In [8]:
```
cenario = cv2.imread('./Cenario.png')
wally = cv2.imread('./Wally(scale4.0).png')
```

In [9]:
```
def find_wally(cenario, wally) -> np.ndarray:
    # Converter as imagens para escala de cinza
    cenario_gray = cv2.cvtColor(cenario, cv2.COLOR_BGR2GRAY)
    wally_gray = cv2.cvtColor(wally, cv2.COLOR_BGR2GRAY)

    # Inicializar o SIFT
    sift = cv2.SIFT_create()
    keypoints_cenario, descritores_cenario = sift.detectAndCompute(cenario_gray, None)
    keypoints_wally, descritores_wally = sift.detectAndCompute(wally_gray, None)

    # Inicializar o FLANN matcher
    index_params = dict(algorithm=1, trees=5)
    search_params = dict(checks=50)
    flann = cv2.FlannBasedMatcher(index_params, search_params)

    # Encontrar as correspondências usando KNN
    matches = flann.knnMatch(descritores_wally, descritores_cenario, k=2)

    good_matches = []
    for m, n in matches:
        if m.distance < 0.75 * n.distance:
            good_matches.append(m)

    src_pts = np.float32([keypoints_wally[m.queryIdx].pt for m in good_matches]).reshape(-1, 1,
    dst_pts = np.float32([keypoints_cenario[m.trainIdx].pt for m in good_matches]).reshape(-1, 1

    homeografia, _ = cv2.findHomography(src_pts, dst_pts, cv2.RANSAC, 19.0)

    h, w = wally_gray.shape

    center_wally = np.float32([[w/2, h/2]]).reshape(-1, 1, 2)
    center_transformed = cv2.perspectiveTransform(center_wally, homeografia)
```

```python
    center_x, center_y = center_transformed[0][0]

    cenario_highlighted = cv2.circle(cenario, (int(center_x), int(center_y)), 100, (0, 0, 255),

    plt.figure(figsize=(10, 10))
    plt.imshow(cv2.cvtColor(cenario_highlighted, cv2.COLOR_BGR2RGB))
```

In [10]:

```python
find_wally(cenario, wally)
```